ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO
BÀI TẬP LỚN HỌC MÁY

Ứng dụng SVM, Naive Bayes, Logistic Regression, XGBoost vào bài toán phân loại review quần áo phụ nữ

GVHD: Th.S Võ Thanh Hùng

SVTH1:
SVTH2:
SVTH3:

Thành phố Hồ Chí Minh, tháng 11/2026

Contents

1 Giới thiệu bài toán **4**
1.1 Bối cảnh và mục tiêu đề tài . . . 4
1.2 Dữ liệu và bài toán học máy . . . 4
1.3 Các thách thức phương pháp luận . . . 4

2 Dữ liệu và tiền xử lý **5**
2.1 Mô tả tập dữ liệu . . . 5
2.2 Phân tích khám phá dữ liệu (EDA) . . . 5
2.2.1 Phân tích giá trị khuyết thiếu . . . 5
2.2.2 Phân tích phân bố nhãn mục tiêu và độ dài văn bản . . . 5
2.2.3 Phân tích rò rỉ mục tiêu giữa Rating và Recommended IND . . . 6
2.2.4 Phân tích các đặc trưng phụ trợ . . . 6
2.3 Quy trình tiền xử lý và phân chia dữ liệu . . . 7

3 Mô hình và phương pháp giải quyết bài toán **8**
3.1 Biểu diễn dữ liệu văn bản (Text Representation) . . . 8
3.1.1 So sánh phương pháp Tokenization . . . 8
3.1.2 Cơ sở toán học của TF-IDF . . . 8
3.2 Lựa chọn đặc trưng (Feature Selection) . . . 9
3.3 Các mô hình học máy giải quyết bài toán . . . 10
3.3.1 Support Vector Machine (SVM) . . . 10
3.3.2 Hồi quy Logistic (Logistic Regression) . . . 11
3.3.3 Multinomial Naive Bayes . . . 11
3.3.4 XGBoost (Extreme Gradient Boosting) . . . 12
3.4 Thước đo đánh giá và tinh chỉnh siêu tham số . . . 12
3.4.1 Thước đo đánh giá cho dữ liệu mất cân bằng . . . 12
3.4.2 Mô hình cơ sở (Baseline Models) . . . 13
3.4.3 Chiến lược tinh chỉnh siêu tham số bằng RandomizedSearchCV . . . 13
3.5 Kỹ thuật mở rộng nâng cao . . . 14
3.5.1 Học kết hợp (Ensemble Learning) . . . 14
3.5.2 Tích hợp siêu dữ liệu (XGBoost with Metadata) . . . 15
3.5.3 Xây dựng Pipeline hoàn chỉnh cho mô hình SVM . . . 15

4 Thực nghiệm và kết quả **17**
4.1 So sánh tổng hợp các mô hình . . . 17
4.2 Phân tích hiện tượng quá khớp (Overfitting Analysis) . . . 18
4.3 Ma trận nhầm lẫn và Báo cáo phân loại . . . 18
4.4 Các từ có ảnh hưởng lớn nhất (Most Influential Terms) . . . 19
4.5 Phân tích lỗi dự đoán (Error Analysis) . . . 19

5 Thảo luận **20**

6 Kết luận và hướng phát triển **21**

6.1 Kết luận 21

6.2 Hạn chế của đề tài 21

6.3 Hướng phát triển 21

List of Figures

1 Phân bố nhãn Recommended IND và Biểu đồ tần số độ dài đánh giá 6
2 Tác động của việc giảm chiều đặc trưng (k-best) lên F1-Score 10
3 Phân bố F1-Score so với thời gian huấn luyện và ảnh hưởng của số đặc trưng k trong quá trình tinh chỉnh SVM 14
4 So sánh hiệu năng F1-Score giữa các phương pháp Ensemble 15
5 Biểu đồ so sánh các chỉ số hiệu năng giữa các mô hình trên tập kiểm thử 17
6 Ma trận nhầm lẫn của 4 mô hình đạt hiệu năng Macro-F1 hàng đầu 18
7 Top 20 từ/cụm từ có hệ số ảnh hưởng mạnh nhất đến quyết định phân loại của Logistic Regression 19

List of Tables

1 Mô tả các thuộc tính trong bộ dữ liệu Women's E-Commerce Clothing Reviews 5
2 Thống kê giá trị khuyết thiếu trong tập dữ liệu 5
3 Tỷ lệ nhãn Recommended IND tương ứng với các mức Rating 6
4 So sánh hiệu năng giữa CountVectorizer và TfidfVectorizer trên mô hình LinearSVC 8
5 F1-Score của các phương pháp lựa chọn đặc trưng theo số lượng đặc trưng k 9
6 So sánh hiệu năng các hàm Kernel của SVM trên tập dữ liệu thử nghiệm 11
7 Kết quả thực nghiệm của các mô hình cơ sở (Baseline) 13
8 Tổng hợp không gian tìm kiếm và cấu hình siêu tham số tối ưu qua RandomizedSearchCV 14
9 So sánh hiệu năng giữa hai phương pháp Ensemble Learning 15
10 Bảng so sánh tổng hợp hiệu năng các mô hình trên tập kiểm thử 17
11 So sánh Macro-F1 giữa tập huấn luyện và tập kiểm thử (Khoảng cách Gap) 18
12 Báo cáo phân loại chi tiết của mô hình Logistic Regression (tuned) 19

1 Giới thiệu bài toán

1.1 Bối cảnh và mục tiêu đề tài

Trong thương mại điện tử, các đánh giá sản phẩm (*reviews*) của khách hàng là nguồn dữ liệu phản hồi quan trọng giúp doanh nghiệp nắm bắt thị hiếu, nâng cao chất lượng sản phẩm và tối ưu hóa trải nghiệm mua sắm. Bài toán đặt ra là phân loại tự động thái độ và quyết định của khách hàng dựa trên nội dung bài đánh giá.

1.2 Dữ liệu và bài toán học máy

Đề tài sử dụng bộ dữ liệu **Women's E-Commerce Clothing Reviews** từ Kaggle, bao gồm 23.486 đánh giá sản phẩm thời trang nữ thực tế từ một nhà bán lẻ.

- Dạng bài toán: Phân loại nhị phân (*Binary Classification*).
- Đầu vào (Input): Văn bản đánh giá của khách hàng, được tạo bằng cách ghép nối tiêu đề đánh giá (`Title`) và nội dung chi tiết (`Review Text`). Trong thí nghiệm mở rộng, mô hình tích hợp thêm độ tuổi (`Age`) và các biến phân loại danh mục sản phẩm.
- Đầu ra (Label): Biến nhị phân `Recommended IND`, trong đó:
  - 1: Khách hàng đề xuất sản phẩm (*Recommended*).
  - 0: Khách hàng không đề xuất sản phẩm (*Not Recommended*).

1.3 Các thách thức phương pháp luận

Trong quá trình xây dựng bài toán học máy, ba thách thức cốt lõi được xác định:

1. Mất cân bằng lớp nghiêm trọng: Bộ dữ liệu có khoảng 82.24% mẫu thuộc lớp 1 và chỉ 17.76% mẫu thuộc lớp 0. Do sự chênh lệch lớn này, thước đo độ chính xác tổng quát (*Accuracy*) không đủ để phản ánh hiệu năng thực tế của mô hình (một mô hình đơn giản luôn dự đoán lớp 1 vẫn đạt độ chính xác hơn 82%). Vì vậy, nghiên cứu tập trung vào chỉ số Macro-F1, F1-Score và Recall của lớp thiểu số (lớp 0).
2. Rò rỉ mục tiêu (Target Leakage): Điểm đánh giá số sao (`Rating`) có mối liên hệ gần như đồng nhất với nhãn `Recommended IND`. Nếu sử dụng `Rating` làm biến đầu vào, bài toán phân loại sẽ trở nên tầm thường và làm mất đi ý nghĩa của việc khai phá văn bản. Do đó, biến `Rating` hoàn toàn bị loại bỏ khỏi không gian đặc trưng.
3. Biểu diễn văn bản phi cấu trúc: Dữ liệu đánh giá là ngôn ngữ tự nhiên không có cấu trúc cố định, đòi hỏi phương pháp trích xuất đặc trưng phù hợp (TF-IDF) nhằm chuyển đổi thành vector số có tính phân biệt cao, đồng thời kiểm soát độ thưa và kích thước không gian từ vựng.

2 Dữ liệu và tiền xử lý

2.1 Mô tả tập dữ liệu

Tập dữ liệu `Womens Clothing E-Commerce Reviews.csv` gồm 23.486 bản ghi với 10 thuộc tính đặc trưng được mô tả chi tiết trong Bảng 1.

Tên cột	Kiểu dữ liệu	Mô tả ý nghĩa
`Clothing ID`	Số nguyên	Mã định danh duy nhất của sản phẩm
`Age`	Số nguyên	Độ tuổi của người đánh giá
`Title`	Văn bản	Tiêu đề ngắn gọn của bài đánh giá
`Review Text`	Văn bản	Nội dung chi tiết bài viết đánh giá của khách hàng
`Rating`	Số nguyên	Điểm đánh giá mức độ hài lòng của khách hàng ($1 \div 5$)
`Recommended IND`	Nhị phân	Nhãn mục tiêu: 1 (Đề xuất) hoặc 0 (Không đề xuất)
`Positive Feedback Count`	Số nguyên	Số lượng người dùng khác bình chọn tích cực cho bài đánh giá
`Division Name`	Phân loại	Phân nhánh cấp cao của dòng sản phẩm thời trang
`Department Name`	Phân loại	Phòng ban/Bộ phận sản phẩm
`Class Name`	Phân loại	Tên phân lớp cụ thể của loại trang phục

Table 1: Mô tả các thuộc tính trong bộ dữ liệu Women's E-Commerce Clothing Reviews

2.2 Phân tích khám phá dữ liệu (EDA)

2.2.1 Phân tích giá trị khuyết thiếu

Kiểm tra tính toàn vẹn của tập dữ liệu trên toàn bộ 23.486 dòng:

Tên cột	Số lượng khuyết	Tỷ lệ (%)	Phương án xử lý
`Title`	3.810	16.22%	Điền chuỗi rỗng (`''`)
`Review Text`	845	3.60%	Điền chuỗi rỗng (`''`)
`Division Name`	14	0.06%	Điền nhãn `'Unknown'`
`Department Name`	14	0.06%	Điền nhãn `'Unknown'`
`Class Name`	14	0.06%	Điền nhãn `'Unknown'`
Các cột còn lại	0	0.00%	Dữ liệu đầy đủ

Table 2: Thống kê giá trị khuyết thiếu trong tập dữ liệu

2.2.2 Phân tích phân bố nhãn mục tiêu và độ dài văn bản

Phân bố nhãn mục tiêu `Recommended IND` cho thấy:

- Lớp 1 (Đề xuất): 19.314 mẫu, chiếm 82.24%.
- Lớp 0 (Không đề xuất): 4.172 mẫu, chiếm 17.76%.

Độ dài văn bản đánh giá (tính theo số lượng từ của `Review Text`) có giá trị trung bình là 58.03 từ, độ lệch chuẩn 30.18 từ, trung vị là 57 từ, bách phân vị 90 đạt 98 từ và độ dài tối đa là 115 từ.

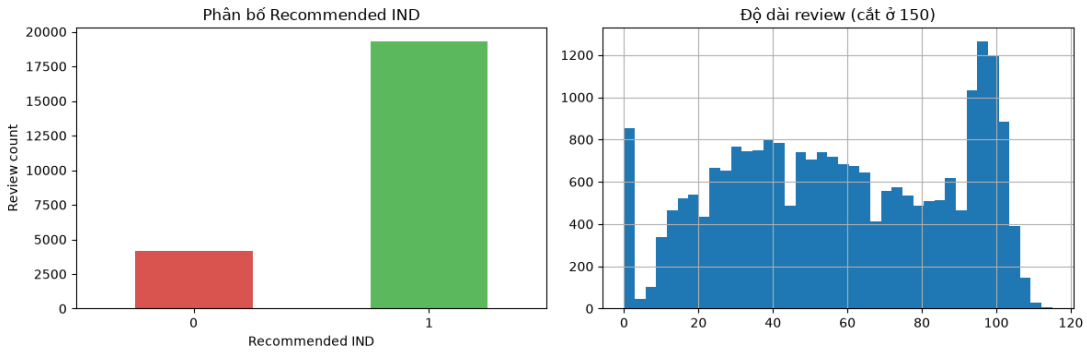


Figure 1: Phân bố nhãn Recommended IND và Biểu đồ tần số độ dài đánh giá

2.2.3 Phân tích rò rỉ mục tiêu giữa Rating và Recommended IND

Để kiểm chứng lý do loại bỏ cột `Rating`, nhóm tiến hành lập bảng kiểm tra chéo tỷ lệ đề xuất theo từng mức điểm đánh giá:

Rating	Tổng số mẫu	Lớp 0 (Không đề xuất)	Lớp 1 (Có đề xuất)	Tỷ lệ lớp 1 (%)
1	842	826	16	1.90%
2	1.565	1.471	94	6.01%
3	2.871	1.682	1.189	41.41%
4	5.077	168	4.909	96.69%
5	13.131	25	13.106	99.81%
Tổng	**23.486**	**4.172**	**19.314**	**82.24%**

Table 3: Tỷ lệ nhãn Recommended IND tương ứng với các mức Rating

Kết quả ở Bảng 3 khẳng định khách hàng cho 1 và 2 sao hầu như chắc chắn không đề xuất sản phẩm (trên 94%), trong khi khách hàng cho 4 và 5 sao gần như tuyệt đối đồng ý đề xuất (trên 96%). Do đó, `Rating` mang tín hiệu rò rỉ trực tiếp mục tiêu phân loại và phải bị loại bỏ để mô hình học cách phân biệt thông qua ngữ nghĩa văn bản.

2.2.4 Phân tích các đặc trưng phụ trợ

- **Độ tuổi (`Age`)**: Phân bố từ 18 đến 99 tuổi, độ tuổi trung bình là 43.20 tuổi ($\pm$12.28), tứ phân vị $Q_1 = 34$, trung vị 41, $Q_3 = 52$ tuổi. Nhóm khách hàng chủ yếu thuộc độ tuổi từ 30 đến 55.
- **Phân nhánh (`Division Name`)**: Gồm 3 nhóm chính: General (58.97%), General Petite (34.57%) và Initmates (6.40%).
- **Bộ phận (`Department Name`)**: Gồm 6 nhóm chính: Tops (44.57%), Dresses (26.91%), Bottoms (16.18%), Intimate (7.39%), Jackets (4.39%) và Trend (0.51%).
- **Phân loại trang phục (`Class Name`)**: Gồm 20 lớp cụ thể, chiếm tỷ trọng cao nhất là Dresses (26.91%), Knits (20.62%), Blouses (13.19%), Sweaters (6.08%) và Pants (5.91%).

2.3 Quy trình tiền xử lý và phân chia dữ liệu

Quy trình chuẩn bị dữ liệu phục vụ huấn luyện bao gồm các bước:

(i) **Tích hợp nội dung văn bản**: Điền giá trị rỗng cho `Title` và `Review Text`, sau đó ghép thành một trường văn bản duy nhất `text` = `Title` + `' '` + `Review Text`. Việc kết hợp này tận dụng tiêu đề ngắn gọn nhưng chứa nhiều từ ngữ cảm xúc cô đọng của người đánh giá.

(ii) **Xử lý biến phân loại**: Điền nhãn `'Unknown'` cho 14 giá trị khuyết thiếu trong `Division Name`, `Department Name` và `Class Name`.

(iii) **Phân chia tập huấn luyện và kiểm thử (Train/Test Split)**: Bộ dữ liệu được chia theo tỷ lệ 80:20 với kỹ thuật lấy mẫu phân tầng (*Stratified Split*) dựa trên nhãn mục tiêu `Recommended IND` (`random_state=42`).

- Tập huấn luyện (*Train Set*): 18.788 mẫu (chiếm 80.0%), tỷ lệ lớp 1 là 82.24%.
- Tập kiểm thử (*Test Set*): 4.698 mẫu (chiếm 20.0%), tỷ lệ lớp 1 là 82.24%.

Tập kiểm thử được giữ độc lập hoàn toàn và chỉ sử dụng cho giai đoạn đánh giá cuối cùng.

(iv) **Tính toán trọng số bù trừ mất cân bằng lớp**: Tính toán tỷ lệ mẫu âm trên mẫu dương trên tập huấn luyện:

$$\text{scale_pos_weight} = \frac{\sum(y_{\text{train}} == 0)}{\sum(y_{\text{train}} == 1)} = \frac{3348}{15440} \approx 0.216 \tag{1}$$

Hệ số này được sử dụng trực tiếp để hiệu chỉnh hàm mất mát trong mô hình XGBoost.

3 Mô hình và phương pháp giải quyết bài toán

Phần này trình bày phương pháp và quy trình giải quyết bài toán phân loại đánh giá sản phẩm thời trang nữ (*Women's E-Commerce Clothing Reviews*). Dữ liệu được đưa qua các giai đoạn: biểu diễn văn bản, lựa chọn đặc trưng, huấn luyện các mô hình học máy gồm Support Vector Machine (SVM), Logistic Regression, Multinomial Naive Bayes và XGBoost, cùng các kỹ thuật nâng cao gồm tối ưu siêu tham số, học kết hợp (Ensemble Learning) và tích hợp siêu dữ liệu (Metadata).

3.1 Biểu diễn dữ liệu văn bản (Text Representation)

Trước khi đưa dữ liệu vào các mô hình học máy, văn bản đánh giá được chuyển đổi từ dạng chuỗi ký tự ban đầu sang vector đặc trưng số thông qua quá trình Tokenization. Các đánh giá có `Review Text` hoặc `Title` khuyết thiếu được xử lý điền chuỗi rỗng và ghép nối thành một trường văn bản thống nhất.

3.1.1 So sánh phương pháp Tokenization

Nhóm tiến hành so sánh hai phương pháp mã hóa văn bản phổ biến bằng một mô hình chuẩn (*LinearSVC*) trên tập dữ liệu:

- **CountVectorizer**: Biểu diễn mỗi từ bằng tần số xuất hiện trong văn bản (Bag-of-Words), không xét thứ tự từ.
- **TfidfVectorizer**: Đếm số lần xuất hiện của từ trong văn bản và chuẩn hóa bằng nghịch đảo tần suất xuất hiện của từ đó trên toàn bộ tập dữ liệu (TF-IDF).

Phương pháp Tokenize	Accuracy	F1-Score	Thời gian (giây)
CountVectorizer	0.8734	0.9238	4.05
TfidfVectorizer	**0.8902**	**0.9348**	**1.40**

Table 4: So sánh hiệu năng giữa CountVectorizer và TfidfVectorizer trên mô hình LinearSVC

Kết quả thực nghiệm ở Bảng 4 cho thấy `TfidfVectorizer` vừa đạt hiệu năng vượt trội vừa có thời gian thực thi nhanh hơn rõ rệt (1.40 giây so với 4.05 giây), do đó `TfidfVectorizer` được lựa chọn làm phương pháp trích xuất đặc trưng chính cho toàn bộ quy trình.

3.1.2 Cơ sở toán học của TF-IDF

TF-IDF giảm trọng số của các từ xuất hiện phổ biến trong nhiều văn bản và tăng trọng số của các từ có tính phân biệt cao:

$$\text{tfidf}(t,d) = \text{tf}(t,d) \times \text{idf}(t), \qquad \text{idf}(t) = \ln \frac{1+n}{1+\text{df}(t)} + 1 \tag{2}$$

Trong đó, n là tổng số văn bản trong tập dữ liệu và $\text{df}(t)$ là số văn bản có chứa từ t. Đây là công thức có làm trơn (smooth IDF) theo cài đặt của scikit-learn. Các vector đặc trưng sau đó được chuẩn hóa theo chuẩn L_2:

$$v_{\text{norm}} = \frac{v}{\|v\|_2} = \frac{v}{\sqrt{\sum_j v_j^2}} \tag{3}$$

Ngoài ra, kỹ thuật `sublinear_tf=True` được sử dụng nhằm thay thế tần suất từ tf bằng $1 + \ln(\text{tf})$, giúp giảm thiểu ảnh hưởng áp đảo của các từ lặp lại quá nhiều lần. Các ngưỡng `min_df` (loại bỏ từ hiếm) và `max_features` (giới hạn từ vựng) được đưa vào kiểm thử để tránh làm bùng nổ số chiều. Để ngăn chặn hoàn toàn hiện tượng rò rỉ dữ liệu (*data leakage*), bộ trích xuất đặc trưng được đặt bên trong cấu trúc `Pipeline`, đảm bảo từ vựng và trọng số IDF chỉ được học trên phần tập huấn luyện của từng fold trong quá trình kiểm định chéo.

3.2 Lựa chọn đặc trưng (Feature Selection)

Dữ liệu văn bản sau khi chuyển sang không gian n-gram thường tạo ra số chiều rất lớn chứa nhiều đặc trưng thưa và từ nhiễu. Kỹ thuật lựa chọn đặc trưng theo phương pháp lọc (*Filter Method*) thông qua `SelectKBest` được áp dụng với hai hàm tính điểm thống kê:

- **Chi-Square (χ^2)**: Kiểm tra tính độc lập thống kê giữa sự xuất hiện của từ và nhãn phân loại:

$$\chi^2 = \sum \frac{(O - E)^2}{E} \tag{4}$$

  với O là tần số quan sát thực tế và E là tần số kỳ vọng theo giả thiết độc lập.

- **ANOVA F-Score**: Đánh giá tỷ số phương sai giữa các nhóm nhãn với phương sai nội bộ từng nhóm ($F = \frac{\text{MSB}}{\text{MSW}}$).

Nhóm tiến hành khảo sát số lượng đặc trưng giữ lại $k \in \{500, 1000, 2000, 3000\}$ trên mô hình LinearSVC:

Số lượng đặc trưng k	**ANOVA F-Score**	**Chi-Square (χ^2)**
500	0.9378	0.9361
1000	0.9393	0.9383
2000	0.9380	0.9382
3000	0.9366	0.9369

Table 5: F1-Score của các phương pháp lựa chọn đặc trưng theo số lượng đặc trưng k

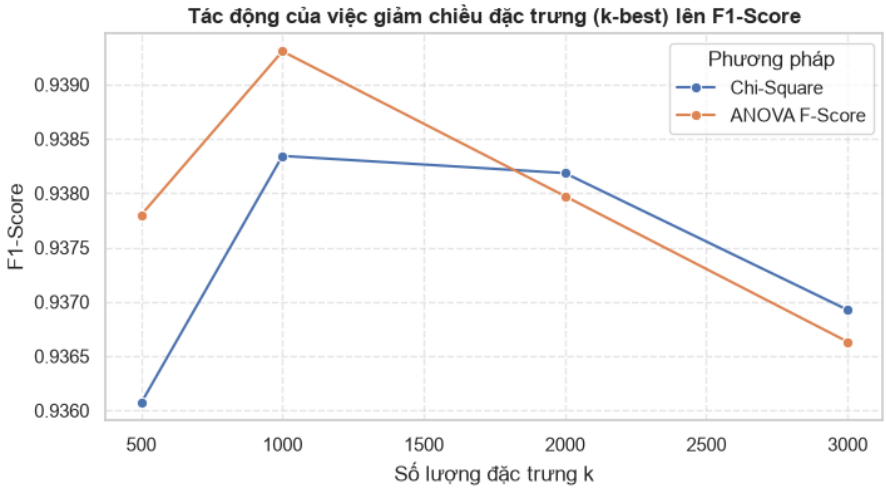


Figure 2: Tác động của việc giảm chiều đặc trưng (k-best) lên F1-Score

Qua Bảng 5 và Hình 2, việc rút gọn không gian đặc trưng về khoảng $k = 1000 \div 2000$ giúp duy trì và tối ưu F1-score so với việc giữ lại toàn bộ từ vựng, đồng thời làm giảm đáng kể chi phí tính toán trong các bước huấn luyện tiếp theo.

3.3 Các mô hình học máy giải quyết bài toán

Bốn thuật toán học máy được triển khai để giải quyết bài toán phân loại nhị phân (0: Không đề xuất, 1: Có đề xuất sản phẩm):

3.3.1 Support Vector Machine (SVM)

Mô hình Support Vector Machine tìm kiếm một siêu phẳng phân tách hai lớp sao cho khoảng cách (lề - margin) từ các điểm luyện tập gần nhất (các Support Vector) đến ranh giới quyết định là lớn nhất. Để giải quyết bài toán khi các lớp không thể phân tách tuyến tính trực tiếp trong không gian ban đầu, các hàm Kernel $K(x, x') = \langle \phi(x), \phi(x') \rangle$ được ứng dụng để ánh xạ các điểm dữ liệu vào không gian nhiều chiều hơn. Bốn dạng Kernel được khảo sát:

- **Linear Kernel**: Tìm siêu phẳng trực tiếp trong không gian gốc:

$$K(x, x') = x^\top x' \tag{5}$$

- **Radial Basis Function (RBF) Kernel**: Ánh xạ dữ liệu vào không gian vô hạn chiều dựa trên khoảng cách Euclidean:

$$K(x, x') = \exp\left(-\gamma \|x - x'\|^2\right) \tag{6}$$

- **Polynomial Kernel**: Ánh xạ phi tuyến thông qua việc kết hợp các bậc lũy thừa:

$$K(x, x') = (\gamma x^\top x' + r)^d \quad (d = 2) \tag{7}$$

- **Sigmoid Kernel**: Hoạt động tương tự hàm kích hoạt nơ-ron, phù hợp với dữ liệu nhị phân thưa:

$$K(x, x') = \tanh\left(\gamma x^\top x' + r\right) \tag{8}$$

SVM Kernel	Accuracy	F1-Score	Thời gian huấn luyện (giây)
SVC (Linear)	0.8817	0.9307	6.21
SVC (RBF)	0.8721	0.9268	9.49
SVC (Poly, deg=2)	0.8550	0.9181	11.34
SVC (Sigmoid)	**0.8819**	**0.9309**	**6.19**

Table 6: So sánh hiệu năng các hàm Kernel của SVM trên tập dữ liệu thử nghiệm

Kernel Sigmoid mang lại F1-score cao nhất (0.9309) cùng thời gian huấn luyện nhanh nhất (6.19 giây), tiếp theo là Linear Kernel. Cả hai được đưa vào không gian tìm kiếm siêu tham số chi tiết ở giai đoạn sau.

3.3.2 Hồi quy Logistic (Logistic Regression)

Logistic Regression ước lượng xác suất hậu nghiệm một quan sát thuộc lớp 1 thông qua hàm kích hoạt sigmoid:

$$P(y = 1 \mid x) = \sigma(w^\top x + b) = \frac{1}{1 + e^{-(w^\top x + b)}} \tag{9}$$

Mô hình gán nhãn 1 khi $P(y = 1 \mid x) \geq 0.5$. Để kiểm soát nguy cơ quá khớp và xử lý bài toán mất cân bằng lớp (82.2% lớp 1 và 17.8% lớp 0), hàm mục tiêu sử dụng chuẩn hóa L_2 cùng trọng số mẫu s_i:

$$\min_{w,b} \frac{1}{2}\|w\|_2^2 + C \sum_i s_i \left[-y_i \ln p_i - (1 - y_i) \ln(1 - p_i)\right] \tag{10}$$

Trong đó, C là nghịch đảo của cường độ điều chuẩn. Tham số `class_weight='balanced'` tự động gán trọng số s_i nghịch với tần suất của các lớp nhằm bù đắp cho lớp thiểu số. Thuật toán tối ưu `lbfgs` được sử dụng nhằm hội tụ nhanh trên ma trận TF-IDF thưa.

3.3.3 Multinomial Naive Bayes

Multinomial Naive Bayes áp dụng định lý Bayes kết hợp giả định độc lập có điều kiện giữa các từ khi biết trước nhãn lớp:

$$P(c \mid d) \propto P(c) \prod_t P(t \mid c)^{x_t} \tag{11}$$

Dạng tương đương trên thang đo logarit (log-posterior) là:

$$\hat{c} = \arg\max_c \left[\ln P(c) + \sum_t x_t \ln P(t \mid c)\right] \tag{12}$$

Xác suất có điều kiện của từ t trong lớp c được ước lượng bằng phương pháp làm trơn cộng Lidstone/Laplace:

$$\hat{\theta}_{ct} = \frac{N_{ct} + \alpha}{N_c + \alpha|V|} \tag{13}$$

với $\alpha > 0$ là hệ số làm trơn giúp tránh xác suất bằng 0 cho các từ chưa xuất hiện, N_{ct} là tổng trọng số TF-IDF của từ t trong lớp c, và $|V|$ là kích thước từ vựng. Mô hình có chi phí tính toán rất thấp và hoạt động trực tiếp trên các giá trị TF-IDF không âm.

3.3.4 XGBoost (Extreme Gradient Boosting)

XGBoost là thuật toán gradient boosting xây dựng một tổ hợp cộng dồn tuần tự gồm các cây quyết định. Tại mỗi bước lặp t, một cây mới $f_t(x_i)$ được bổ sung để tối ưu hàm mục tiêu:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(x_i) \tag{14}$$

với η là tốc độ học (*learning rate*). Hàm mục tiêu bao gồm hàm mất mát logistic kết hợp thành phần điều chuẩn kiểm soát độ phức tạp của cây:

$$\mathcal{L} = \sum_i \ell(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \qquad \Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2 \tag{15}$$

trong đó T là số lượng nút lá và w là vector trọng số tại các lá. Bằng khai triển Taylor bậc hai của hàm mất mát, trọng số tối ưu tại lá j được tính trực tiếp:

$$w_j^* = -\frac{G_j}{H_j + \lambda} \tag{16}$$

với $G_j = \sum_{i \in I_j} g_i$ và $H_j = \sum_{i \in I_j} h_i$ lần lượt là tổng gradient bậc một và bậc hai của các mẫu thuộc lá j.

Để xử lý mất cân bằng lớp, tham số `scale_pos_weight` được thiết lập bằng tỷ số giữa số lượng mẫu âm và số lượng mẫu dương trong tập huấn luyện:

$$\text{scale_pos_weight} = \frac{n_{\text{neg}}}{n_{\text{pos}}} = \frac{3348}{15440} \approx 0.216 \tag{17}$$

Quá trình huấn luyện XGBoost được tối ưu tốc độ bằng thuật toán phân phối histogram (`tree_method='hist'`) và tăng tốc phần cứng thông qua GPU (`device='cuda'`).

3.4 Thước đo đánh giá và tinh chỉnh siêu tham số

3.4.1 Thước đo đánh giá cho dữ liệu mất cân bằng

Do tỷ lệ nhãn lớp trong tập dữ liệu có sự chênh lệch lớn (khoảng 82.2% lớp 1 và 17.8% lớp 0), chỉ số Accuracy thông thường không phản ánh chính xác hiệu năng vì một mô hình luôn đoán nhãn 1 cũng có thể đạt độ chính xác 82.2%. Do đó, các chỉ số sau được lựa chọn làm căn cứ đánh giá:

- **Precision, Recall, F1-Score từng lớp**:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{18}$$

  Đặc biệt chú trọng đến Recall và F1-Score của lớp 0 (đánh giá không đề xuất).

- **Macro-F1**: Trung bình không trọng số của F1-Score giữa hai lớp:

$$\text{Macro-F1} = \frac{1}{2}\left(F_1^{(0)} + F_1^{(1)}\right) \tag{19}$$

  Macro-F1 được chọn làm tiêu chí mục tiêu chính để tối ưu và xếp hạng các cấu hình mô hình.

- **ROC-AUC**: Đánh giá khả năng phân biệt và xếp hạng phân phối xác suất dự đoán của mô hình, độc lập với ngưỡng phân loại cố định 0.5.

3.4.2 Mô hình cơ sở (Baseline Models)

Trước khi tinh chỉnh siêu tham số, ba mô hình cơ sở được huấn luyện trên cùng tập phân chia train/test (80:20, có phân tầng *stratify*) để làm mốc đối chứng:

Mô hình	Accuracy	F1 (Lớp 1)	F1 (Lớp 0)	Macro-F1	Recall (Lớp 0)	ROC-AUC
LogReg (baseline)	0.9044	0.9402	0.7618	0.8510	0.8599	0.9501
XGBoost (baseline)	0.8995	0.9376	0.7415	0.8396	0.8108	0.9419
NaiveBayes (baseline)	0.9040	0.9433	0.6879	0.8156	0.5952	0.9484

Table 7: Kết quả thực nghiệm của các mô hình cơ sở (Baseline)

3.4.3 Chiến lược tinh chỉnh siêu tham số bằng RandomizedSearchCV

Quá trình tinh chỉnh siêu tham số được thực hiện bằng `RandomizedSearchCV` kết hợp kiểm định chéo phân tầng 5 lớp (*Stratified 5-Fold Cross-Validation*) với hàm mục tiêu là `scoring='f1_macro'`. Chiến lược tìm kiếm ngẫu nhiên cho phép khảo sát hiệu quả các không gian tham số liên tục dạng log-uniform và tham số rời rạc.

Bảng 8 tổng hợp không gian tìm kiếm, cấu hình tối ưu và điểm kiểm định chéo tốt nhất của từng mô hình:

Mô hình	Không gian tìm kiếm	Cấu hình tối ưu (Best Parameters)	Best CV Score
SVM	$C \in \{0.1, 0.5, 1, 5, 10\}$; $\gamma \in \{\text{'scale'}, \text{'auto'}, 0.01, 0.1\}$; kernel $\in \{\text{'linear'}, \text{'sigmoid'}, \text{'rbf'}\}$; $k \in \{1000, 2000, 3000\}$; max_features $\in \{3000, 5000\}$; ngram $\in \{(1,1), (1,2)\}$	kernel = 'sigmoid'; $C = 0.5$; $\gamma =$ 'scale'; $k = 2000$; max_features $= 5000$; ngram $= (1,1)$; sublinear_tf $=$ False	0.9320 (CV F1)
LogisticRegression	$C \sim \text{loguniform}(10^{-2}, 10^{2})$; ngram $\in \{(1,1), (1,2), (1,3)\}$; min_df $\in \{1,2,3,5\}$; max_features $\in \{\text{None}, 20k, 50k\}$; sublinear_tf $\in \{\text{True}, \text{False}\}$	$C \approx 10.506$; ngram $= (1,2)$; min_df $= 2$; max_features $= 20000$; sublinear_tf $=$ False	0.8559(Macro-F1)
Naive Bayes	$\alpha \sim \text{loguniform}(10^{-3}, 2)$; fit_prior $\in \{\text{True}, \text{False}\}$; ngram $\in \{(1,1), (1,2), (1,3)\}$; min_df $\in \{1,2,3,5\}$; max_features $\in \{\text{None}, 20k, 50k\}$	$\alpha \approx 0.0540$; fit_prior $=$ True; ngram $= (1,3)$; min_df $= 5$; max_features $= 20000$; sublinear_tf $=$ False	0.8285(Macro-F1)
XGBoost	$\eta \sim \text{loguniform}(0.03, 0.3)$; max_depth $\in [3,8]$; $N \in [200, 600]$; min_child $\in [1,7]$; subsample $\sim \mathcal{U}(0.6, 1.0)$; colsample $\sim \mathcal{U}(0.4, 1.0)$; max_feat $\in \{3k, 5k, 10k\}$	$\eta \approx 0.0635$; max_depth $= 7$; $N = 566$; min_child $= 2$; subsample ≈ 0.9315; colsample ≈ 0.4271; max_feat $= 5000$; ngram $= (1,2)$	0.8294(Macro-F1)

Table 8: Tổng hợp không gian tìm kiếm và cấu hình siêu tham số tối ưu qua RandomizedSearchCV

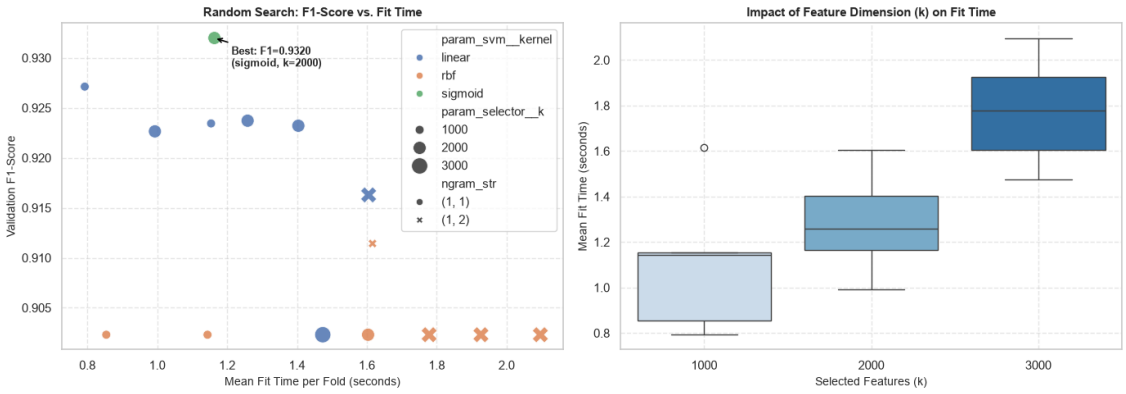


Figure 3: Phân bố F1-Score so với thời gian huấn luyện và ảnh hưởng của số đặc trưng k trong quá trình tinh chỉnh SVM

3.5 Kỹ thuật mở rộng nâng cao

3.5.1 Học kết hợp (Ensemble Learning)

Nhằm cải thiện độ chính xác và giảm phương sai dự đoán cho mô hình SVM, hai kỹ thuật học kết hợp được thử nghiệm trên không gian vector đặc trưng TF-IDF:

- **Bagging**: Giảm phương sai bằng cách huấn luyện song song nhiều mô hình cơ sở (`LinearSVC`) trên các tập con mẫu lấy ngẫu nhiên có hoàn lại (*Bootstrap Aggregating*, `n_estimators=10`, `max_samples=0.8`).

- **AdaBoost**: Giảm độ chệch bằng cách huấn luyện tuần tự các bộ phân loại yếu, tập trung tăng trọng số cho các mẫu bị phân loại sai ở bước trước (*Adaptive Boosting*, `n_estimators=50`).

Mô hình Ensemble	Accuracy	F1-Score
Bagging	**0.8934**	**0.9369**
AdaBoostClassifier	0.8412	0.9113

Table 9: So sánh hiệu năng giữa hai phương pháp Ensemble Learning

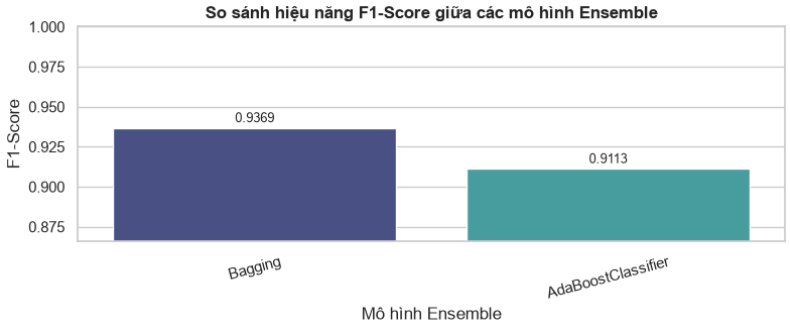


Figure 4: So sánh hiệu năng F1-Score giữa các phương pháp Ensemble

Kết quả ở Bảng 9 và Hình 4 cho thấy Bagging đạt hiệu năng vượt trội rõ rệt so với AdaBoost trên không gian đặc trưng văn bản nhiều chiều. Do đó, kiến trúc Bagging được tích hợp vào mô hình SVM cuối cùng.

3.5.2 Tích hợp siêu dữ liệu (XGBoost with Metadata)

Bên cạnh văn bản đánh giá thuần túy, bộ dữ liệu còn cung cấp các thông tin ngữ cảnh gồm độ tuổi khách hàng (`Age`) và danh mục sản phẩm (`Division Name`, `Department Name`, `Class Name`). Kiến trúc `ColumnTransformer` được xây dựng để ghép nối:

- Đặc trưng văn bản: `TfidfVectorizer` với các siêu tham số tối ưu tìm được từ XGBoost.
- Đặc trưng phân loại danh mục: Mã hóa One-Hot (`OneHotEncoder(handle_unknown='ignore')`).
- Đặc trưng số học: Cột `Age` truyền trực tiếp (`passthrough`).

Mô hình kết hợp `XGBoost + metadata` được huấn luyện và đánh giá trên tập kiểm thử nhằm kiểm chứng mức độ đóng góp của dữ liệu dạng bảng bổ trợ vào quyết định phân loại.

3.5.3 Xây dựng Pipeline hoàn chỉnh cho mô hình SVM

Tổng hợp các kết quả thực nghiệm về trích xuất đặc trưng, lựa chọn đặc trưng, siêu tham số và học kết hợp, mô hình SVM cuối cùng được xây dựng thành một quy trình khép kín:

1. **Vector hóa**: Sử dụng `TfidfVectorizer` với các siêu tham số: `max_features` = 5000, `ngram_range` = (1, 1) và `sublinear_tf` = False.
2. **Lọc đặc trưng**: `SelectKBest` (χ^2, $k = 2000$), giảm số chiều đặc trưng từ $(18788, 5000)$ xuống $(18788, 2000)$.
3. **Học tổ hợp**: `BaggingClassifier` sử dụng bộ phân loại cơ sở `SVC` (kernel Sigmoid, $C = 0.5$, $\gamma =$ scale), `n_estimators` = 10, tỷ lệ lấy mẫu con `max_samples` = 0.8.

Mô hình hội tụ trong 17.57 giây và hoàn tất toàn bộ quá trình xử lý - đánh giá trong 25.17 giây, đạt độ chính xác kiểm thử 90% và Macro-F1 là 0.80.

4 Thực nghiệm và kết quả

Toàn bộ các mô hình sau khi huấn luyện và tinh chỉnh siêu tham số được đánh giá độc lập trên cùng một tập kiểm thử (*Test Set*) gồm 4.698 mẫu đã được phân tầng.

4.1 So sánh tổng hợp các mô hình

Bảng 10 tổng hợp hiệu năng của tất cả các mô hình học máy được triển khai trong nghiên cứu, sắp xếp giảm dần theo chỉ số mục tiêu Macro-F1.

Mô hình	Accuracy	F1 (Lớp 1)	F1 (Lớp 0)	Macro-F1	Recall (Lớp 0)	ROC-AUC	Fit Time (s)
LogReg (tuned)	**0.9106**	**0.9450**	0.7605	**0.8528**	0.7988	0.9478	2.86
LogReg (baseline)	0.9044	0.9402	**0.7618**	0.8510	**0.8599**	**0.9501**	3.32
XGBoost (tuned)	0.9059	0.9418	0.7553	0.8485	0.8168	0.9444	8.91
XGBoost + metadata	0.9051	0.9413	0.7517	0.8465	0.8084	0.9443	10.40
XGBoost (baseline)	0.8995	0.9376	0.7415	0.8396	0.8108	0.9419	6.87
NaiveBayes (tuned)	0.9017	0.9407	0.7116	0.8262	0.6826	0.9445	3.76
NaiveBayes (baseline)	0.9040	0.9433	0.6879	0.8156	0.5952	0.9484	**1.21**
SVM (Bagging + Sigmoid)	0.9000	0.9400	0.6600	0.8000	0.5700	–	17.57

Table 10: Bảng so sánh tổng hợp hiệu năng các mô hình trên tập kiểm thử

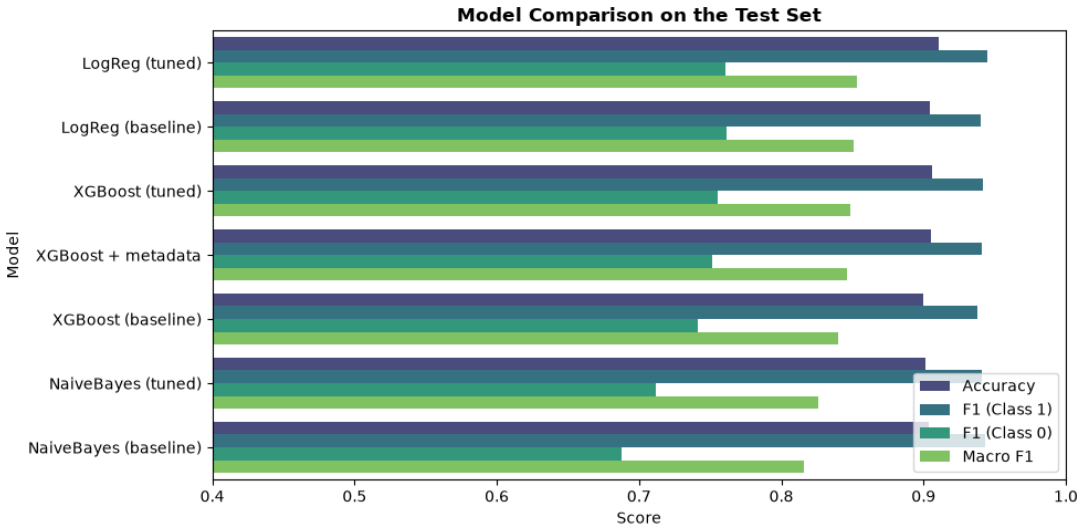


Figure 5: Biểu đồ so sánh các chỉ số hiệu năng giữa các mô hình trên tập kiểm thử

Từ Bảng 10 và Hình 5, Logistic Regression sau khi tinh chỉnh đạt Macro-F1 cao nhất (0.8528) và thời gian huấn luyện nhanh (2.86 giây). XGBoost sau tuning đạt hiệu năng rất cạnh tranh (Macro-F1 0.8485, Recall lớp 0 đạt 0.8168). Các mô hình Naive Bayes và SVM hoàn chỉnh đạt độ chính xác Accuracy xấp xỉ 90% nhưng có F1 và Recall trên lớp thiểu số thấp hơn.

4.2 Phân tích hiện tượng quá khớp (Overfitting Analysis)

Khoảng cách sai lệch giữa điểm Macro-F1 trên tập huấn luyện (*train*) và tập kiểm thử (*test*) được sử dụng làm thước đo phát hiện nguy cơ quá khớp:

$$\text{Gap} = \text{Macro-F1}_{\text{train}} - \text{Macro-F1}_{\text{test}} \tag{20}$$

Mô hình	Macro-F1 (Train)	Macro-F1 (Test)	Gap (Train - Test)
NaiveBayes (baseline)	0.9557	0.8156	0.1401
LogReg (tuned)	0.9562	0.8528	0.1034
XGBoost + metadata	0.9330	0.8465	0.0866
XGBoost (baseline)	0.9251	0.8396	0.0855
XGBoost (tuned)	0.9327	0.8485	0.0842
NaiveBayes (tuned)	0.8904	0.8262	0.0642
LogReg (baseline)	0.9068	0.8510	**0.0558**

Table 11: So sánh Macro-F1 giữa tập huấn luyện và tập kiểm thử (Khoảng cách Gap)

Kết quả ở Bảng 11 cho thấy Naive Bayes baseline có độ chênh lệch lớn nhất (0.1401) do chưa được tối ưu hóa tham số làm trơn α. Ngược lại, sau khi tinh chỉnh siêu tham số, khoảng cách sai lệch của Naive Bayes giảm xuống còn 0.0642. Đối với XGBoost, việc kiểm soát độ sâu cây (`max_depth=7`), tỷ lệ lấy mẫu con (`subsample=0.9315`, `colsample=0.4271`) và trọng số lá tối thiểu (`min_child_weight=2`) giữ khoảng cách ở mức an toàn ($0.0842 \div 0.0866$). Logistic Regression baseline đạt độ ổn định cao nhất với Gap chỉ 0.0558.

4.3 Ma trận nhầm lẫn và Báo cáo phân loại

Hình 6 thể hiện ma trận nhầm lẫn của 4 mô hình dẫn đầu trên tập kiểm thử (gồm 835 mẫu lớp 0 và 3.863 mẫu lớp 1).

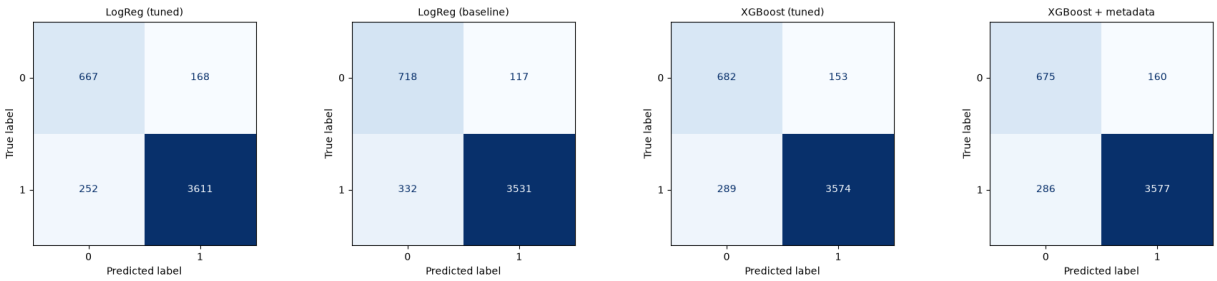


Figure 6: Ma trận nhầm lẫn của 4 mô hình đạt hiệu năng Macro-F1 hàng đầu

Báo cáo phân loại chi tiết của mô hình tốt nhất (Logistic Regression sau tinh chỉnh) được trình bày trong Bảng 12.

Lớp phân loại	Precision	Recall	F1-Score	Hỗ trợ (Support)
Không đề xuất (Lớp 0)	0.73	0.80	0.76	835
Có đề xuất (Lớp 1)	0.96	0.93	0.95	3.863
Accuracy		0.91		4.698
Macro Avg	0.84	0.87	0.85	4.698
Weighted Avg	0.91	0.91	0.91	4.698

Table 12: Báo cáo phân loại chi tiết của mô hình Logistic Regression (tuned)

4.4 Các từ có ảnh hưởng lớn nhất (Most Influential Terms)

Dựa trên hệ số hồi quy w của mô hình Logistic Regression tối ưu:

- **Hệ số âm**: Đẩy xác suất dự đoán về phía nhãn 0 (Không đề xuất).
- **Hệ số dương**: Đẩy xác suất dự đoán về phía nhãn 1 (Có đề xuất).

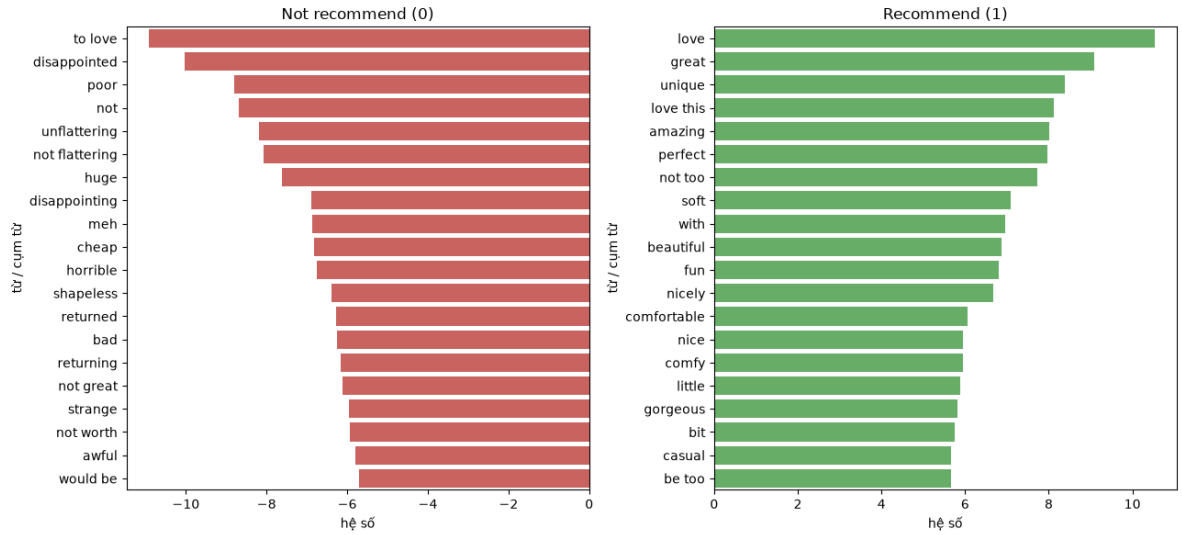


Figure 7: Top 20 từ/cụm từ có hệ số ảnh hưởng mạnh nhất đến quyết định phân loại của Logistic Regression

Hình 7 cho thấy các từ chỉ sự thất vọng về phom dáng, chất lượng hoặc hành vi trả hàng mang trọng số âm lớn nhất: *huge*, *unflattering*, *returned*, *returning*, *cheap*, *disappointed*, *poorly*, *boxy*. Ngược lại, các từ thể hiện sự hài lòng cao mang trọng số dương lớn nhất: *love*, *great*, *perfect*, *compliments*, *comfortable*, *flattering*, *soft*.

4.5 Phân tích lỗi dự đoán (Error Analysis)

Khảo sát các trường hợp mô hình phân loại sai với độ tự tin dự đoán cao nhất ($P(\text{recommend})$ gần 0 hoặc 1) chỉ ra hai nguyên nhân chính:

1. **Thực tế KHÔNG đề xuất (0) nhưng mô hình dự đoán đề xuất (1)** ($P \approx 0.99 \div 1.0$):

- Khách hàng mở đầu bằng khen ngợi tổng quát hoặc kiểu dáng nhưng gặp vấn đề về kích cỡ/đường may buộc phải trả lại: ví dụ đánh giá *"Love this dress I also have this dress in 3/4..."* hoặc *"Cute pant Unfortunately i had to size down twice..."*.
- Mô hình dựa trên túi từ (Bag-of-Words/TF-IDF) bắt gặp các từ tích cực mạnh (*love*, *cute*, *beautiful*) nhưng không bắt được ngữ cảnh đảo ngược của từ nối (*unfortunately*, *however*).

2. **Thực tế CÓ đề xuất (1) nhưng mô hình dự đoán không đề xuất (0) ($P \leq 0.008$)**:
   - Khách hàng đánh giá tiêu đề mang tính cảnh báo hoặc chê chi tiết phụ nhưng tổng thể vẫn hài lòng và đồng ý giới thiệu: ví dụ *"Much thinner I was so excited..."*, *"Great dress, poor stitching..."*, *"I recommend with caveats..."*.
   - Sự xuất hiện của các từ mang trọng số âm mạnh (*terrible*, *poor*, *thinner*) khiến mô hình hạ thấp xác suất dự đoán.

5 Thảo luận

Dựa trên kết quả thực nghiệm, nhóm rút ra các nhận xét chuyên sâu:

1. **Ý nghĩa của các thước đo đánh giá**: Độ chính xác (Accuracy) có sự khác biệt rất nhỏ giữa các mô hình (đều dao động quanh 90% ÷ 91%), trong khi Macro-F1 và Recall của lớp 0 phản ánh rõ nét khả năng nhận diện lớp thiểu số. Điều này chứng minh việc chọn Macro-F1 làm mục tiêu tối ưu là hoàn toàn đúng đắn.

2. **Hiệu năng giữa mô hình tuyến tính và mô hình cây**: Logistic Regression sau khi tinh chỉnh siêu tham số đạt Macro-F1 cao nhất (0.8528) với thời gian huấn luyện chỉ 2.86 giây. Mặc dù XGBoost là mô hình phi tuyến mạnh mẽ và có hỗ trợ tăng tốc GPU, hiệu năng của XGBoost (0.8485) không vượt qua mô hình tuyến tính trên không gian đặc trưng TF-IDF thưa và nhiều chiều. Hiện tượng này phù hợp với lý thuyết học máy cho dữ liệu văn bản: các ranh giới quyết định tuyến tính trong không gian thưa nhiều chiều thường mang lại tính tổng quát hóa cao và ít bị ảnh hưởng bởi nhiễu cục bộ.

3. **Độ chênh lệch giữa các mô hình dẫn đầu**: Chênh lệch Macro-F1 giữa Logistic Regression và XGBoost là tương đối nhỏ (khoảng 0.004). Sự sai khác này có thể chịu ảnh hưởng từ cách phân chia ngẫu nhiên một lần tập dữ liệu (*single train-test split*). Cần tiến hành đánh giá lặp lại nhiều lần để có kết luận khái quát hơn.

4. **Vai trò của siêu dữ liệu (Metadata)**: Việc bổ sung thông tin độ tuổi (`Age`) và danh mục sản phẩm (`Division`, `Department`, `Class`) không làm tăng hiệu năng của XGBoost (Macro-F1 đạt 0.8465 so với 0.8485 của XGBoost chỉ dùng văn bản). Điều này chứng minh tín hiệu quyết định khách hàng có đề xuất sản phẩm hay không tập trung chủ yếu trong nội dung cảm xúc của bài đánh giá, trong khi các thuộc tính nhân khẩu học và danh mục đóng góp rất ít thông tin phân biệt.

6 Kết luận và hướng phát triển

6.1 Kết luận

Báo cáo đã hoàn thành trọn vẹn quy trình giải quyết bài toán phân loại đánh giá thời trang nữ theo đúng yêu cầu môn học Machine Learning:

- Phân tích đặc điểm dữ liệu, nhận diện và xử lý triệt để hai thách thức cốt lõi: mất cân bằng lớp và rò rỉ mục tiêu từ thuộc tính `Rating`.
- Hiện thực và đánh giá 4 thuật toán học máy đại diện cho các trường phái khác nhau: Support Vector Machine, Logistic Regression, Multinomial Naive Bayes và XGBoost.
- Áp dụng thành công các kỹ thuật học máy nâng cao: lựa chọn đặc trưng (*Feature Selection* qua Chi-Square/ANOVA), tối ưu siêu tham số (*RandomizedSearchCV* với *Stratified 5-Fold CV*), học kết hợp (*Bagging/AdaBoost*) và tích hợp siêu dữ liệu đa phương thức (*ColumnTransformer*).
- Mô hình Logistic Regression tối ưu đạt hiệu năng dẫn đầu với Macro-F1 đạt 0.8528, độ chính xác 91.06% và thời gian thực thi ngắn.

6.2 Hạn chế của đề tài

- Thí nghiệm chỉ thực hiện trên một lần phân chia train/test cố định; chưa tính toán khoảng tin cậy (*confidence interval*) qua kiểm định lặp lại nhiều lần.
- Không gian siêu tham số và số vòng tìm kiếm ngẫu nhiên (*n_iter*) còn bị giới hạn bởi tài nguyên tính toán.
- Biểu diễn TF-IDF dạng túi từ chưa nắm bắt được ngữ cảnh trật tự từ khoảng cách xa, cấu trúc ngữ pháp phức tạp, ngữ cảnh phủ định đa tầng hoặc cách diễn đạt mỉa mai (*sarcasm*).
- Ngưỡng quyết định xác suất đang được cố định ở mức mặc định 0.5, chưa được tối ưu hóa theo đường cong ROC hoặc bài toán chi phí thiệt hại cụ thể.

6.3 Hướng phát triển

- Nghiên cứu và thử nghiệm các mô hình mạng nơ-ron hồi tiếp (BiLSTM, GRU) và mạng tích chập một chiều (1D-CNN) để biểu diễn chuỗi từ theo thứ tự thời gian.
- Ứng dụng các mô hình ngôn ngữ dựa trên kiến trúc Transformer tiền huấn luyện (BERT, RoBERTa, DistilBERT) nhằm nắm bắt sâu sắc ngữ cảnh hai chiều và ngữ nghĩa tiềm ẩn trong các bài đánh giá phức tạp.
- Tối ưu hóa ngưỡng cắt xác suất (*Threshold Tuning*) kết hợp kỹ thuật tái lấy mẫu nâng cao (SMOTE, Focal Loss) nhằm gia tăng hơn nữa Recall của lớp khách hàng không đề xuất.

References

[1] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.

[2] Chen, T., Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), 785–794.

[3] Bergstra, J., Bengio, Y. (2012). *Random Search for Hyper-Parameter Optimization*. Journal of Machine Learning Research, 13, 281–305.

[4] Agarap, A. F. (2018). *Statistical Analysis on E-Commerce Reviews, with Sentiment Classification using Bidirectional Recurrent Neural Network (RNN)*. arXiv preprint arXiv:1805.03687.

[5] Women's E-Commerce Clothing Reviews Dataset. Kaggle. https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews.